

1. ¿Cuál de las siguientes funciones sirven como kernel para estimación de densidades? Probar su afirmación.

a. $K(x) = I(|x| < 1)/2$

b. $K(x) = I(0 < x < 1)$

c. $K(x) = 1/x$

d. $K(x) = \frac{3}{2}(2x+1)(1-2x)I(-\frac{1}{2} < x < \frac{1}{2})$

e. $K(x) = \frac{3}{4}(1-x^2)I(|x| < 1)$.

1.a) 1. $\int_{\mathbb{R}} K_1(x) dx = \int_{-1}^1 \frac{dx}{2} = 1$.
Rectangular

2. K_1 es par

3. $K_1(x) \geq 0 \quad \forall x$

4. $\int_{\mathbb{R}} x K_1(x) dx = \int_{-1}^1 x dx = 0$
impr.

5. $\int_{\mathbb{R}} x^2 K_1(x) dx = \int_{-1}^1 x^2 dx = 2x^3 \Big|_0^1 = 2 < \infty$
par par

SÍ sirve //

1.b) 1. $\int_{\mathbb{R}} K_2(x) dx = \int_0^1 dx = 1$.

2. $K_2(x) \neq K_2(-x) = 0$

NO sirve //

1.c) 1. $\int_{\mathbb{R}} K_3(x) dx = \int_{\mathbb{R}} \frac{1}{x} dx = \ln(x) \Big|_{-\infty}^{\infty} = \ln(x) \Big|_0^{\infty} = \frac{1}{\frac{a \rightarrow \infty}{b \rightarrow 0}} \ln\left(\frac{a}{b}\right) = \infty$. \therefore NO sirve

1.d) 1. $\int_{\mathbb{R}} K_4(x) dx = \int_{-1/2}^{1/2} \frac{3}{2}(2x+1)(1-2x) dx = \frac{3}{4} \int_{-1/2}^{1/2} (u+1)(1-u) du = -\frac{3}{4} \int_{-1}^1 (u^2-1) du = -\frac{3}{2} \int_0^1 (u^2-1) du = -\frac{3}{2} \left(\frac{u^3}{3} - u \right) \Big|_0^1 = -\frac{3}{2} \left(\frac{1}{3} - 1 \right) = -\frac{3}{2} \left(\frac{1-3}{3} \right) = 1$.
 $u=2x$
 $\frac{1}{2} du = dx$
 $u \in [-1, 1]$
 $u(1/2) = -1$
 $u(1/2) = 1$
par
2. $K_4(x) \leq 0 \quad \forall x$,
NO sirve

1.e) 1. $\int_{\mathbb{R}} K_5(x) dx = \frac{3}{4} \int_{-1}^1 (1-x^2) dx = \frac{3}{2} \int_0^1 (1-x^2) dx = \frac{3}{2} \left(x - \frac{x^3}{3} \right) \Big|_0^1 = \frac{3}{2} \left(1 - \frac{1}{3} \right) = \frac{3}{2} \cdot \frac{2}{3} = 1$.
Egmechnikar

2. $K_5(x) = K_5(x)$
par

3. $K_5(x) \geq 0 \quad \forall x$

4. $\int_{\mathbb{R}} x K_5(x) dx = \int_{-1}^1 x K_5(x) dx = 0$
impr par

5. $\int_{\mathbb{R}} x^2 K_5(x) dx = 2 \int_0^1 x^2 \left(\frac{3}{2} (1-x^2) \right) dx < \infty$
par par

SÍ sirve

2. Con el siguiente conjunto de datos: 12, 13, 12, 15, 15, 16, 19, 20, 25 estimar $p^* = P(X < 15)$ usando un estimador de densidad basado en un kernel gaussiano con $h_n = \sqrt{3/n}$ "a mano" (pueden hacer los cálculos con R, pero sin usar ninguna de las funciones predefinidas).


• $n = 9$

• Queremos

$$P[X < 15] \approx \int_{-\infty}^{15} \hat{f}_n(x) dx = \int_{-\infty}^{15} \frac{1}{nh_n} \sum_{i=1}^n K_0\left(\frac{x_i - x}{h_n}\right) dx$$

$$= \int_{-\infty}^{15} \frac{1}{3 \cdot \sqrt{9}} \sum_{i=1}^9 K_0\left(\frac{x_i - x}{\sqrt{3/9}}\right) dx = \frac{1}{3\sqrt{3}} \int_{-\infty}^{15} \sum_{i=1}^9 \phi\left(\frac{x_i - x}{\sqrt{1/3}}\right) dx$$

$$= \frac{1}{3\sqrt{3}} \sum_{i=1}^9 \int_{-\infty}^{15} \phi\left(\frac{x_i - x}{\sqrt{1/3}}\right) dx \stackrel{\text{par}}{=} \frac{1}{3\sqrt{3}} \sum_{i=1}^9 \int_{-\infty}^{15} \phi\left(\frac{x - x_i}{\sqrt{1/3}}\right) dx$$



$$\left. \begin{array}{l} \bullet \quad u = (x - x_i) / \sqrt{1/3} \\ \bullet \quad \sqrt{1/3} du = dx \\ \bullet \quad u(-\infty) = -\infty \\ \bullet \quad u(15) = (15 - x_i) / \sqrt{1/3} \end{array} \right\} = \frac{1}{9} \sum_{i=1}^9 \Phi\left(\frac{15 - x_i}{\sqrt{1/3}}\right)$$

Tarea 4. Fecha de entrega: Jueves 30 de abril de 2020.

Problemas

- ¿Cuál de las siguientes funciones sirven como kernel para estimación de densidades? Probar su afirmación.
 - $K(x) = I(|x| < 1)/2$
 - $K(x) = I(0 < x < 1)$
 - $K(x) = 1/x$
 - $K(x) = \frac{3}{2}(2x+1)(1-2x)I(-\frac{1}{2} < x < \frac{1}{2})$
 - $K(x) = \frac{3}{4}(1-x^2)I(|x| < 1)$.
- Con el siguiente conjunto de datos: 12, 13, 12, 15, 15, 16, 19, 20, 25 estimar $p^* = P(X < 15)$ usando un estimador de densidad basado en un kernel gaussiano con $h_n = \sqrt{3/n}$ “a mano” (pueden hacer los cálculos con R, pero sin usar ninguna de las funciones predefinidas).
- Generar 20 observaciones de una distribución mezcla donde la mitad de las observaciones son normales estándar y la otra mitad son datos normales $\mathcal{N}(1, 0.64)$. Usar la función `density` de R para crear un estimador de la densidad.
- Usar datos de Michelson del paquete `HistData` (contiene conjuntos de datos históricos). Estos datos son 100 mediciones de la velocidad de la luz en el aire que se obtuvieron por Albert Michelson en 1879.

```
library(HistData)
data(Michelson)
head(Michelson)
```

```
velocity
1      850
2      740
3      900
4     1070
5      930
6      850
```

Construir un estimador de densidad de kernel que sientan que da una mejor imagen visual de la información que proveen los datos. ¿Qué parámetros escogieron?

- Consideren la función

$$s(x) = \begin{cases} 1 - x + x^2 - x^3 & 0 < x \leq 1 \\ -2(x-1) - 2(x-1)^2 & 1 < x \leq 2 \\ -4 - 6(x-2) - 2(x-2)^2 & 2 < x \leq 3 \end{cases}$$

¿ $s(x)$ define un spline suave cúbico en $[0, 3]$ con nodos 1 y 2? Si lo es, graficar los 3 polinomios en $[0, 3]$.

- Simular un conjunto de datos como sigue:

```
u <- runif(100)
x <- sort(u)
y <- x^2 + 0.1*rnorm(100)
```

Ajustar un spline interpolado a los datos simulados.

7. Con los datos del archivo `motor.dat`. Estos datos corresponden a datos simulados de accidentes de motocicleta. La variable `time` es el tiempo en milisegundos desde el impacto y `accel` es la aceleración de la cabeza del muñeco (g).

- Construir un estimador LOESS a los datos.
- ajustar un spline a los datos.

8. Usar el teorema de Taylor para expandir las siguientes sucesiones a términos de orden h_n^2 , donde $h = h_n \rightarrow 0$ cuando $n \rightarrow \infty$:

- a. $\sin^2(\pi/4 + h)$
- b. $e^{h^2+h} - e^{h^2}$
- c. $\exp(-e^{x-h})$
- d. $\frac{x-h}{x+h}$

9. Basado en una muestra X_1, \dots, X_n , un estimador M -bipeso de ubicación se define como la solución $\hat{\theta}_c$, a

$$\sum_{i=1}^n \xi_c \left(\frac{X_i - \theta}{\hat{\sigma}} \right) = 0$$

donde $\xi_c(x) = x(c^2 - x^2)^2 I(|x| < c)$ y $\hat{\sigma}$ es un estimador de escala.

Mostrar que $\hat{\theta}_c$ es igual a la moda del estimado del kernel de densidad basado en X_1, \dots, X_n con ancho de banda $h = c\hat{\sigma}$ y el kernel bipeso $K(x) = \frac{15}{16}(1 - x^2)^2 I(|x| < 1)$

10. Usar R para construir una gráfica para los datos de radiocarbón que se encuentran en el conjunto de datos `radioc` del paquete `sm` que muestra un estimador de la varianza del error σ^2 basado en la suma de los residuales al cuadrado y grados de libertad aproximados como una función del parámetro h . La matriz de pesos S se puede construir a través de la función `sm.weight(x, y, h)`. Agregar a la gráfica una línea horizontal correspondiente a la diferencia basado en el estimador de Gasser *et al.* (1986), que es disponible en la función `sm.sigma(x, y)`.

¿A qué valor el estimador basado en la suma de los residuales al cuadrado converge cuando el parámetro de suavizamiento se hace muy grande?